

## Zadanie 2. Dokumentacja dla algorytmu ewolucyjnego

Artem Kukushkin,317140

### 1. Cel projektu

Celem projektu jest zaprojektowanie i zaimplementowanie algorytmu ewolucyjnego, który będzie w stanie zoptymalizować funkcje celu z benchmarku CEC2017 (F3 i F19) przy wymiarowości  $n = 10$ . Algorytm ewolucyjny zostanie porównany pod względem zbieżności z implementacją algorytmu gradientu prostego, a wyniki będą uśredniane z wielu uruchomień.

### 2. Opis algorytmu ewolucyjnego

Algorytm ewolucyjny jest techniką optymalizacji inspirowaną procesami naturalnymi, takimi jak selekcja, krzyżowanie i mutacja. Celem jest znalezienie najlepszego rozwiązania problemu optymalizacji w danym środowisku.

#### Kroki algorytmu ewolucyjnego:

1. **Inicjalizacja populacji:** Tworzymy początkową populację rozwiązań (wektory liczb) w określonym zakresie.
2. **Ocena dopasowania:** Każde rozwiązanie w populacji jest oceniane na podstawie wartości funkcji celu.
3. **Selekcja:** Populacja jest selekcionowana metodą turniejową. Wybierani są najlepsi osobniki do dalszej reprodukcji.
4. **Krzyżowanie:** Z wybranych rodziców tworzymy nowe rozwiązania (potomków) przez krzyżowanie (np. krzyżowanie jednopunktowe).
5. **Mutacja:** Wprowadzamy losowe zmiany w niektórych rozwiązaniach, aby wprowadzić różnorodność do populacji.
6. **Zakończenie:** Algorytm kończy się po określonej liczbie pokoleń. Najlepsze rozwiązanie zostaje wybrane jako wynik.

### 3. Szczegóły implementacji

- **Funkcje pomocnicze:**
  - `inicjalizuj_populacje`: Generuje początkową populację.
  - `ocena_dopasowania`: Ocena każdej jednostki w populacji na podstawie funkcji celu.
  - `selekcja_turniejowa`: Selekcja osobników z populacji do dalszej reprodukcji.
  - `krzyzowanie_jednopunktowe`: Operacja krzyżowania dwóch rodziców.
  - `mutacja`: Mutacja losowa, która wprowadza zmiany do rozwiązania.
- **Algorytm główny:** Funkcja `algorytm_ewolucyjny` implementuje cały algorytm ewolucyjny, w tym inicjalizację populacji, selekcję, krzyżowanie, mutację oraz aktualizację populacji na przestrzeni wielu pokoleń.
- **Parametry algorytmu:**
  - `rozmiar_populacji`: Liczba jednostek w populacji.
  - `wymiar`: Wymiar przestrzeni poszukiwań ( $n = 10$ ).
  - `zakres`: Zakres dla zmiennych (np.  $(-100, 100)$ ).
  - `liczba_pokolen`: Liczba pokoleń w algorytmie.

- rozmiar\_turnieju: Liczba uczestników w selekcji turniejowej.
- prawdopodobieństwo\_mutacji: Prawdopodobieństwo mutacji dla każdego rozwiązania.

#### 4. Porównanie algorytmu ewolucyjnego z gradientem prostym

Zbadano zbieżność algorytmu ewolucyjnego na dwóch funkcjach celu (F3 i F19 z benchmarku CEC2017) oraz porównano go z prostym algorytmem gradientu.

##### Wyniki:

- **Funkcja F3:**

Średnia wartość funkcji celu: 33226.54

- **Funkcja F19:**

Średnia wartość funkcji celu: 24811.16

#### 5. Parametry eksperymentu

- Wymiar przestrzeni:  $n = 10$
- Zakres dla zmiennych:  $(-100, 100)$
- Liczba powtórzeń: 10
- Liczba pokoleń: 200
- Rozmiar populacji: 50
- Rozmiar turnieju: 3
- Prawdopodobieństwo mutacji: 0.1

#### 6. Wnioski

Na podstawie przeprowadzonych eksperymentów algorytm ewolucyjny skutecznie optymalizuje funkcje F3 oraz F19 w przestrzeni wymiarowej  $n = 10$ . Wyniki są stabilne i uśrednione z wielu uruchomień, co pozwala uzyskać rzetelną miarę zbieżności algorytmu.